به نام خدا



دانشگاه صنعتی شریف

درس آمار و کاربردها، نیم‌سال پاییز ۱۴۰۵

عنوان : بررسی ارتباط بیان ژن گیرنده‌ی استروژن با وضعیت بالینی گیرنده، سن و مرحله‌ی بیماری در تومورهای اولیه‌ی سرطان مهاجم پستان

مسیر ب، گزارش فاز اول

نام و نام خانوادگی :سامان بدیعی

کد دانشجویی :۴۰۲۱۷۰۰۹۲

نشانی گیت هاب : https://github.com/SMBD1972/TCGA-BRCA_project

فهرست مطالب

۱. مقدمه و سؤال پژوهش
۲. منشأ داده
۳. واحد مشاهده و ساختار داده
۴. نمونه‌گیری و قابلیت تعمیم
۵. متغیرها و مقیاس اندازه‌گیری
۶. تطبیق شناسه‌ها و جریان داده
۷. ممیزی کیفیت داده
۸. الگوی نبودن وجه‌ها
۹. انتخاب ویژگی‌های مولکولی و آمار توصیفی
۱۰. نمودارها
۱۱. مقایسه‌ی توصیفی دو گروه
۱۲. سؤال نهایی
۱۳. محدودیت‌ها
۱۴. منابع

۱. مقدمه و سؤال پژوهش

بیشتر سرطان‌های مهاجم پستان به هورمون استروژن وابسته‌اند. سلول‌های این تومورها پروتئین گیرنده‌ی استروژن را دارند، که با اتصال به هورمون، رشد و تقسیم سلول را تحریک می‌کند. وضعیت این گیرنده در بالین با رنگ‌آمیزی بافت تومور تعیین می‌شود و مبنای تصمیم‌گیری برای درمان هورمونی است [۲]. از سوی دیگر، فعالیت ژن سازنده‌ی همین گیرنده را می‌توان با اندازه‌گیری مولکولی بیان ژن سنجید. بنابراین یک ویژگی زیستی واحد با دو روش متفاوت اندازه‌گیری شده است: یکی در سطح پروتئین و با مشاهده‌ی پاتولوژیست، و دیگری در سطح بیان ژن و به‌صورت کمی.
سؤال اصلی این پروژه این است: آیا در تومورهای اولیه‌ی سرطان مهاجم پستان، بیان ژن گیرنده‌ی استروژن بین گروه‌های گیرنده‌مثبت و گیرنده‌منفی تفاوت دارد، و آیا این بیان پس از درنظرگرفتن سن و مرحله‌ی بیماری با وضعیت گیرنده و بیان چند ژن همکار ارتباط دارد؟
این سؤال برای مسیر چندوجهی پروژه مناسب است، زیرا به‌طور طبیعی داده‌ی بالینی و داده‌ی مولکولی را کنار هم قرار می‌دهد، متغیر پاسخ آن کمی است، و تنها از تعداد کمی ژن با نقش زیستی شناخته‌شده استفاده می‌کند. بر اساس منابع علمی، انتظار می‌رود بیان ژن گیرنده‌ی استروژن در گروه گیرنده‌مثبت بالاتر باشد، با بیان ژن‌های همکار آن هم‌جهت و با بیان نشانگر تکثیر رابطه‌ی معکوس داشته باشد.

۲. منشأ داده

داده‌های این پروژه از بخش سرطان مهاجم پستان پروژه‌ی اطلس ژنوم سرطان [۱] گرفته شده است، که در درگاه داده‌ی ژنومی مؤسسه‌ی ملی سرطان آمریکا نگهداری می‌شود. این پروژه یک مطالعه‌ی مشاهده‌ای است: نمونه‌ی تومور بیمارانی که در مراکز درمانی همکار تحت جراحی قرار گرفته بودند، تقریباً در سال‌های ۲۰۰۶ تا ۲۰۱۴ جمع‌آوری شده و با روش‌های یکسان پردازش شده است. هیچ مداخله یا تخصیص تصادفی‌ای در کار نبوده است.
در این پروژه فقط از داده‌های عمومی و بدون محدودیت دسترسی استفاده شد. دو نوع داده به کار رفت: داده‌ی بیان ژن نمونه‌های تومور اولیه، که با روش پردازش استاندارد درگاه تولید شده و در واحد استانداردشده گزارش شده است؛ و داده‌ی بالینی از دو منبع، یعنی جدول بالینی اصلی درگاه، شامل سن، جنس و مرحله، و جدول بیمار از فایل‌های بالینی تفصیلی، شامل وضعیت گیرنده‌ی استروژن و وضعیت یائسگی. داده‌ها در تاریخ ۱۰ آبان ۱۴۰۵ از نسخه‌ی **Data Release 46.0 – August 10, 2026** درگاه دریافت شدند. دریافت به‌طور کامل با کد و از طریق رابط برنامه‌نویسی درگاه انجام شد، بنابراین قابل بازتولید است.

۳. واحد مشاهده و ساختار داده

داده‌ی این پروژه ساختار سلسله‌مراتبی دارد: هر بیمار می‌تواند چند نمونه‌ی بافتی داشته باشد، هر نمونه می‌تواند به چند ویال و آزمایش تقسیم شود، و هر آزمایش در یک فایل ذخیره می‌شود. داده‌ی بالینی در سطح بیمار ذخیره شده است، در حالی که داده‌ی بیان ژن در سطح نمونه است.
واحد تحلیل در این پروژه بیمار است، زیرا سؤال پژوهش درباره‌ی بیماران است، متغیرهای بالینی برای هر بیمار یک مقدار دارند، و در نظر گرفتن چند نمونه از یک بیمار به‌عنوان مشاهدات مستقل، فرض استقلال را نقض می‌کند. نحوه‌ی تبدیل داده‌ی سطح نمونه به سطح بیمار در بخش ۶ شرح داده شده است.

۴. نمونه‌گیری و قابلیت تعمیم

بیماران این پروژه به‌صورت تصادفی انتخاب نشده‌اند. آن‌ها در مراکز درمانی همکار پروژه تحت جراحی قرار گرفته بودند، بافت تومور به مقدار و کیفیت کافی داشتند، و رضایت داده بودند. بنابراین نمی‌توان نتایج را به همه‌ی بیماران مبتلا به سرطان پستان تعمیم داد. نتایج تنها با احتیاط درباره‌ی بیمارانی مشابه بیماران این پروژه قابل تفسیر است، یعنی بیمارانی که سرطان مهاجم پستان داشتند، جراحی شدند و تومورشان برای آزمایش مولکولی مناسب بود. برای مثال، بیمارانی که بیماری‌شان در زمان تشخیص بیش از حد پیشرفته بود و جراحی نشدند، احتمالاً در این داده کم‌اند؛ تعداد بسیار کم بیماران مرحله‌ی چهار در جدول ۸ با این موضوع سازگار است. افزون بر این، بیشتر مراکز همکار در ایالات متحده بوده‌اند، بنابراین ترکیب جمعیتی، دسترسی به درمان و سایر ویژگی‌های بیماران ممکن است با بیماران کشورهای دیگر متفاوت باشد. این موضوع به تعمیم‌پذیری مربوط است و نه به تصادفی بودن نمونه‌گیری.

۵. متغیرها و مقیاس اندازه‌گیری

جدول ۱۱: متغیرهای اصلی، نوع و نقش آن‌ها

متغیر	وجه	نوع	واحد یا سطوح	نقش
بیان ژن گیرنده‌ی استروژن	مولکولی	کمی پیوسته	لگاریتم مقدار استانداردشده	پاسخ
بیان سه ژن همکار و نشانگر	مولکولی	کمی پیوسته	همان	توضیحی مولکولی
وضعیت گیرنده در رنگ‌آمیزی	بالینی	دودویی	مثبت، منفی	گروه‌بندی و توضیحی اصلی
سن هنگام تشخیص	بالینی	کمی پیوسته	سال	توضیحی، تعدیل
مرحله‌ی بیماری	بالینی	ترتیبی	یک تا چهار	توضیحی، تعدیل
وضعیت یائسگی	بالینی	ترتیبی	پیش، حین، پس	توضیحی ثانویه

مرحله‌ی بیماری با عدد نشان داده می‌شود، ولی متغیر کمی نیست: مرحله‌ی چهار دو برابر مرحله‌ی دو نیست و فاصله‌ی مراحل برابر نیست؛ تنها ترتیب دارند، بنابراین ترتیبی است. بیان ژن از شمارش قطعات خوانده‌شده به دست می‌آید که گسسته است، ولی پس از استانداردسازی و تبدیل لگاریتمی، مقادیر پیوسته‌ای حاصل می‌شود. وضعیت گیرنده هم برای تقسیم بیماران به دو گروه در مقایسه‌ها به کار می‌رود و هم در فاز چهارم به‌صورت متغیر صفر و یک وارد مدل رگرسیون می‌شود. وضعیت یائسگی به‌شدت با سن مرتبط است، بنابراین در مدل‌های چندگانه احتمال چندهم‌خطی آن با سن بررسی خواهد شد. یائسگی در تعریف داده‌ی کامل لحاظ نشد، زیرا متغیر ثانویه است و حدود ۱۰ درصد گمشدگی دارد.

۶. تطبیق شناسه‌ها و جریان داده

در این پروژه، واحد تحلیل بیمار است و نه نمونه‌ی بافتی. اگر یک بیمار بیش از یک بار در داده حضور داشته باشد، فرض استقلال مشاهدات نقض می‌شود و نتایج آماری بیش از حد مطمئن به نظر می‌رسند. بررسی شناسه‌ی نمونه‌ها نشان داد که ۶ بیمار دو نمونه و ۵ بیمار سه نمونه‌ی تومور اولیه بیمار از دو مرکز جمع‌آوری نمونه ۱۱ داشتند، که در مجموع ۱۶ نمونه‌ی اضافه بود (جدول۱). همه‌ی این بودند. این تکرارها دو نوع بودند: در برخی موارد، تکه‌ی دیگری از همان تومور در ویال جداگانه نمونه‌برداری شده بود، و در برخی دیگر، همان نمونه در زمان دیگری دوباره آزمایش شده بود. برای انتخاب یک نمونه به ازای هر بیمار، شناسه‌ها به ترتیب الفبایی مرتب شدند و اولین نمونه نگه داشته شد. در نتیجه، ویال اصلی بر ویال‌های بعدی و آزمایش اصلی بر آزمایش تکراری ترجیح داده شد. این قاعده پیش از مشاهده‌ی مقادیر بیان ژن تعیین شد، و چون ساده و قطعی است، هر بار دقیقاً همان نمونه‌ها را انتخاب می‌کند و قابل بازتولید است.

جدول ۱: تعداد نمونه‌ی تومور اولیه به ازای هر بیمار

تعداد نمونه	تعداد بیمار	تعداد نمونه برای هر بیمار
1084	1084	1
12	6	2
15	5	3
1111	1095	جمع

جدول ۳: جریان داده از نمونه‌های اولیه تا نمونه‌ی تحلیلی

توضیح	تعداد	مرحله
دریافت از درگاه	۱۱۱۱ نمونه	نمونه‌های تومور اولیه با داده‌ی بیان ژن
۱۶ نمونه از ۱۱ بیمار کنار گذاشته شد	۱۰۹۵ بیمار	پس از انتخاب یک نمونه برای هر بیمار
جدول بالینی اصلی	۱۰۹۸ بیمار	بیماران دارای داده‌ی بالینی
	۳ بیمار	فقط داده‌ی بالینی، بدون بیان ژن
هیچ بیماری بیان ژن بدون پرونده نداشت	۱۰۹۵ بیمار	دارای هر دو وجه
۱۲ مرد و ۱ نفر با جنس نامعلوم	۱۰۸۲ بیمار	پس از حذف مردان و جنس نامعلوم
۸۷ بیمار حداقل یکی از گیرنده، سن یا مرحله را ندارند	۹۹۵ بیمار	دارای داده‌ی کامل در سه متغیر اصلی

همان‌طور که در جدول ۲ دیده می‌شود، بزرگ‌ترین کاهش در اندازه‌ی نمونه به دلیل داده‌ی بالینی گمشده بود: ۸۷ بیمار حداقل یکی از سه متغیر اصلی، یعنی وضعیت گیرنده، سن یا مرحله‌ی بیماری را نداشتند. سایر کاهش‌ها کوچک بودند: ۱۶ نمونه‌ی تکراری، و ۱۳ بیمار مرد یا با جنس نامعلوم.
هم‌پوشانی دو وجه داده تقریباً کامل بود، زیرا هیچ بیماری داده‌ی بیان ژن بدون داده‌ی بالینی نداشت و تنها ۳ بیمار داده‌ی بالینی بدون داده‌ی بیان ژن داشتند. تمام حذف‌ها قابل ردیابی‌اند و تعداد بیماران در هر مرحله با مراحل قبل سازگار است.

۷. ممیزی کیفیت داده

۷-۱. ممیزی داده‌ی بالینی

جدول ۳: مشکلات کیفیت داده‌ی بالینی و تصمیم‌های اتخاذشده

مشکل	متغیر	تعداد	تصمیم
دو ردیف توضیحی بالای جدول	جدول بیمار	ردیف ۲	حذف
«کدهای متنی «ارزیابی‌نشده» و «نامشخص	وضعیت گیرنده	51	گمشده
کدهای متنی گمشدگی	یائسگی	124	گمشده
مرحله‌ی غیرقابل ارزیابی یا خالی	مرحله	25	گمشده
سن بر حسب روز ثبت شده	سن	همه	تبدیل به سال
سن خالی	سن	16	گمشده
سن روی سقف ۹۰ سال	سن	10	نگه‌داری، ذکر در محدودیت‌ها
بیماران مرد	جنس	12	حذف از تحلیل اصلی
جنس نامعلوم	جنس	1	حذف
ناسازگاری سن بین دو منبع	سن	0	—
بیمار تکراری	هر دو جدول	0	—

* تعدادها مربوط به جدول‌های بالینی کامل، پیش از ادغام با داده‌ی بیان ژن است.

کدهای متنی مانند «ارزیابی‌نشده» یا «نامعلوم» به‌عنوان داده‌ی گمشده در نظر گرفته شدند، زیرا وضعیت واقعی این بیماران مثبت یا منفی است و تنها برای ما نامعلوم است؛ در نظر گرفتن آن‌ها به‌عنوان یک دسته‌ی جداگانه به معنای فرض وجود نوع سومی از تومور بود که از نظر زیستی معنا .ندارد. زیرمرحله‌های بیماری در چهار مرحله‌ی اصلی ادغام شدند و سن از روز به سال تبدیل شد.
بررسی سازگاری سن در دو منبع بالینی نشان داد که اختلاف در هیچ بیماری از یک سال بیشتر نیست، که با تفاوت روش ثبت، یعنی روز در برابر سال کامل، سازگار است. سن ۱۰ بیمار دقیقاً ۹۰ سال ثبت شده است، که نشان می‌دهد سن‌های بالاتر برای حفظ حریم خصوصی روی این مقدار سقف‌گذاری شده‌اند؛ این بیماران حفظ شدند و موضوع در بخش محدودیت‌ها ذکر شده است. بیماران مرد، ۱۲ نفر، و یک

بیمار با جنس نامعلوم از تحلیل اصلی کنار گذاشته شدند، زیرا تعداد آن‌ها برای هرگونه نتیجه‌گیری معتبر بسیار کم است، زیست هورمونی سرطان پستان در مردان متفاوت است، و یکی از متغیرهای پروژه، یعنی وضعیت یائسگی، برای آن‌ها تعریف‌پذیر نیست. این تصمیم پیش از مشاهده‌ی هر نتیجه‌ای گرفته شد.

۲-۷. ممیزی داده‌ی مولکولی

جدول ۴: بررسی‌های کیفیت داده‌ی بیان ژن

تصمیم	نتیجه	بررسی
—	پس از دانلود مجدد، اندازه‌ی هر ۱۱۱۱ فایل با سرور مطابقت داشت	سلامت فایل‌های دانلودشده
—	ژن در ۱۱۱۱ نمونه ۶۰۶۶۰	ابعاد داده
قاعده‌ی انتخاب، بخش ۶	نمونه از ۱۱ بیمار ۱۶	نمونه‌های تکراری
—	هر ۴ ژن، همه سازنده‌ی پروتئین	پیدا شدن ژن‌های منتخب
—	0	مقادیر گمشده در ۴ ژن
—	0	مقادیر غیرممکن، مثل منفی
نگه‌داری؛ مقادیر واقعی	در ژن گیرنده، تا ۰٫۰۴	مقادیر نزدیک صفر
بررسی تبدیل لگاریتمی	ژن از ۴ ۳	چولگی شدید در مقیاس خام

هیچ مقدار گمشده یا غیرممکنی در بیان چهار ژن منتخب مشاهده نشد. سلامت تمام فایل‌های دانلودشده با مقایسه‌ی اندازه‌ی هر فایل با اطلاعات سرور تأیید شد. مقادیر بسیار پایین بیان ژن گیرنده‌ی استروژن حذف نشدند، زیرا مقادیر واقعی‌اند و نه خطای اندازه‌گیری: این مقادیر عمدتاً به تومورهای گیرنده‌منفی تعلق دارند که ژن در آن‌ها تقریباً خاموش است، و حذف آن‌ها به معنای حذف یکی از دو گروه مورد مقایسه بود. سه ژن از چهار ژن در مقیاس خام چولگی شدید داشتند؛ تبدیل لگاریتمی برای همه‌ی ژن‌ها محاسبه شد، ولی اثر آن برای هر ژن جداگانه در بخش ۹ بررسی شده است.

۸. الگوی نبودن وجه‌ها

جدول ۵: الگوی داده‌ی گمشده در سه متغیر اصلی بالینی

تعداد بیمار	متغیر گمشده
995	هیچ، داده‌ی کامل
48	فقط وضعیت گیرنده
23	فقط مرحله
14	فقط سن
1	وضعیت گیرنده و مرحله
1	وضعیت گیرنده و سن

جدول ۶: مقایسه‌ی توصیفی بیماران دارای داده‌ی کامل و ناقص

ناقص	کامل	ویژگی
87	995	تعداد بیمار
58.2	59.2	میانه‌ی سن، سال
6.6	6.5	میانه‌ی بیان ژن گیرنده، مقیاس لگاریتمی
4.7	4.5	میانه‌ی بیان نشانگر تکثیر، مقیاس لگاریتمی
78.4	77	درصد گیرنده‌مثبت، از بیماران معلوم
23.8	25.1	درصد مرحله‌ی سه یا چهار، از بیماران معلوم

برای بررسی الگوی نبودن وجه‌ها، ابتدا تعداد بیماران دارای هر وجه بررسی شد. هیچ بیماری داده‌ی بیان ژن بدون داده‌ی بالینی نداشت و تنها ۳ بیمار داده‌ی بالینی بدون داده‌ی بیان ژن داشتند (جدول ۲)،

بنابراین محدود شدن به بیماران دارای هر دو وجه تقریباً هیچ بیماری را حذف نمی‌کند. با این حال، از ۱۰۸۲ بیمار زن دارای هر دو وجه، ۸۷ بیمار حداقل یکی از سه متغیر اصلی بالینی را نداشتند. همان‌طور که جدول ۵ نشان می‌دهد، تقریباً تمام این بیماران تنها یک متغیر گمشده داشتند و فقط ۲ بیمار دو متغیر گمشده داشتند؛ بنابراین گمشدگی پراکنده است و نشانه‌ای از یک علت مشترک، مانند ثبت ناقص در یک مرکز خاص، دیده نمی‌شود. برای بررسی اینکه آیا محدود شدن به بیماران دارای داده‌ی کامل ترکیب نمونه را تغییر می‌دهد، این دو گروه از نظر چند ویژگی مقایسه شدند (جدول ۶). دو گروه از نظر سن، بیان ژن گیرنده‌ی استروژن، بیان نشانگر تکثیر، درصد گیرنده‌مثبت و درصد مرحله‌ی پیشرفته بسیار شبیه بودند. به‌ویژه میانه‌ی متغیر پاسخ در دو گروه تقریباً یکسان بود. بنابراین در این مقایسه‌ی توصیفی، نشانه‌ای از اینکه محدود شدن به داده‌ی کامل نمونه را منحرف کند دیده نمی‌شود. با این حال، گروه ناقص تنها ۸۷ بیمار دارد و مقایسه صرفاً توصیفی است، بنابراین نمی‌توان وجود سوگیری را به‌طور قطعی رد کرد. این موضوع در فاز پنجم با تحلیل حساسیت بیشتر بررسی خواهد شد.

۹. انتخاب ویژگی‌های مولکولی و آمار توصیفی

طبق الزامات مسیر ب، به‌جای بررسی هزاران ژن، مجموعه‌ی کوچکی از ژن‌ها انتخاب شد که نقش زیستی آن‌ها در سرطان پستان شناخته‌شده است و پیش از تحلیل داده، بر اساس منابع علمی توجیه شده‌اند. چهار ژن انتخاب شد: یک ژن به‌عنوان متغیر پاسخ، دو ژن از شبکه‌ی همکار گیرنده‌ی استروژن، و یک ژن به‌عنوان نماینده‌ی جنبه‌ای متفاوت از زیست تومور، یعنی سرعت تکثیر. بیان همه‌ی ژن‌ها در واحد استانداردشده‌ی درگاه داده گزارش شده و برای تحلیل، لگاریتم پایه‌ی دوی آن پس از افزودن یک استفاده شده است.

ژن گیرنده‌ی استروژن، متغیر پاسخ

ESR1

این ژن پروتئین گیرنده‌ی استروژن را می‌سازد. این گیرنده پس از اتصال به هورمون استروژن، رشد و تقسیم سلول را تحریک می‌کند. این ژن در تومورهای گیرنده‌مثبت بیان بالا و در تومورهای گیرنده‌منفی بیان بسیار پایینی دارد [۱]. وضعیت گیرنده در بالین با رنگ‌آمیزی پروتئین تعیین می‌شود و مبنای انتخاب درمان هورمونی است [۲]. بیان این ژن متغیر پاسخ این پروژه است، و هدف، بررسی میزان هم‌خوانی آن با وضعیت گیرنده بر اساس رنگ‌آمیزی است.

ژن همکار اول

GATA3

این ژن یک عامل رونویسی است که هویت سلول‌های لومینال پستان را حفظ می‌کند [۳] و با ژن گیرنده‌ی استروژن همکاری دارد، به‌طوری که در تومورهای گیرنده‌مثبت معمولاً بیان بالایی دارد. این ژن همچنین یکی از سه ژنی است که در بیش از ده درصد سرطان‌های پستان جهش دارند، و جهش‌های آن در زیرگروه لومینال بیشتر دیده می‌شود [۱]. به همین دلیل انتظار می‌رود بیان آن با بیان ژن گیرنده‌ی استروژن هم‌جهت باشد، و به‌عنوان یک متغیر توضیحی مولکولی انتخاب شده است.

ژن همکار دوم

FOXA1

این ژن یک عامل رونویسی است که کروماتین فشرده را در نواحی خاصی از ژنوم باز می‌کند و به این ترتیب امکان اتصال گیرنده‌ی استروژن به دی‌ان‌ای را فراهم می‌کند. تقریباً تمام اتصال‌های گیرنده‌ی استروژن به ژنوم به حضور این ژن وابسته است، و پاسخ به درمان هورمونی نیز به آن وابسته است [۴]. بنابراین انتظار می‌رود بیان آن با بیان ژن گیرنده‌ی استروژن هم‌جهت باشد، و به‌عنوان یک متغیر توضیحی مولکولی انتخاب شده است.

نشانگر تکثیر

MKI67

این ژن پروتئینی می‌سازد که فقط در سلول‌های در حال تقسیم وجود دارد و در سلول‌های در حال استراحت دیده نمی‌شود. به همین دلیل، سطح بالای آن نشانه‌ی تکثیر سریع‌تر و تهاجمی‌تر بودن تومور است، و در بالین برای ارزیابی تومورهای پستان استفاده می‌شود [۵]. این ژن جزو شبکه‌ی گیرنده‌ی استروژن نیست، ولی چون تومورهای گیرنده‌منفی معمولاً سرعت تکثیر بیشتری دارند، انتظار می‌رود رابطه‌ی آن با بیان ژن گیرنده‌ی استروژن معکوس باشد. لازم به ذکر است که در این پروژه بیان ژن آن اندازه‌گیری شده است، نه شاخص تکثیر بر اساس رنگ‌آمیزی بافت که در بالین استفاده می‌شود.

جدول ۷: ژن‌های منتخب، نقش آن‌ها در سؤال و رابطه‌ی مورد انتظار

ژن	نقش در سؤال	رابطه‌ی مورد انتظار با ژن گیرنده	منبع
گیرنده‌ی استروژن	متغیر پاسخ	—	۱، ۲
همکار اول	توضیحی مولکولی	هم‌جهت	۱، ۳
همکار دوم	توضیحی مولکولی	هم‌جهت	4
نشانگر تکثیر	توضیحی مولکولی	معکوس	5

۲-۹. توزیع متغیرهای طبقه‌ای

جدول ۸: فراوانی متغیرهای طبقه‌ای در ۱۰۸۲ بیمار نمونه‌ی تحلیلی

متغیر	سطح	تعداد	درصد کل	درصد معتبر
وضعیت گیرنده	منفی	237	21.9	23.0
	مثبت	795	73.5	77.0
	گمشده	50	4.6	–
مرحله	یک	182	16.8	17.2
	دو	611	56.5	57.8
	سه	246	22.7	23.3
	چهار	19	1.8	1.8
	گمشده	24	2.2	–
یائسگی	پیش از یائسگی	227	21.0	23.4
	حین یائسگی	39	3.6	4.0
	پس از یائسگی	705	65.2	72.6
	گمشده	111	10.3	–

* **نکته:** درصد معتبر یعنی درصد از بین بیمارانی که مقدارشان معلوم است.

همان‌طور که جدول ۸ نشان می‌دهد، از بیماران با وضعیت گیرنده‌ی معلوم، ۷۷ درصد گیرنده‌مثبت بودند، که با شیوع شناخته‌شده‌ی این زیرگروه در سرطان پستان سازگار است. بیش از نیمی از بیماران در مرحله‌ی دو قرار داشتند و حدود سه‌چهارم بیماران با وضعیت معلوم، پس از یائسگی بودند. دو زیرگروه بسیار کوچک وجود دارد: مرحله‌ی چهار با ۱۹ بیمار و حین یائسگی با ۳۹ بیمار. تعداد اندک بیماران مرحله‌ی چهار احتمالاً ناشی از نحوه‌ی انتخاب بیماران است، زیرا ورود به این پروژه مستلزم وجود بافت تومور از جراحی بوده و بیماران با بیماری پیشرفته معمولاً جراحی اولیه نمی‌شوند. این دو زیرگروه در تحلیل‌های فازهای بعد عدم قطعیت زیادی خواهند داشت و ممکن است نیاز به ادغام با سطح مجاور داشته باشند. بیشترین درصد گمشدگی مربوط به وضعیت یائسگی، حدود ۱۰ درصد، است.

۳-۹. مرکز و پراکندگی متغیرهای کمی

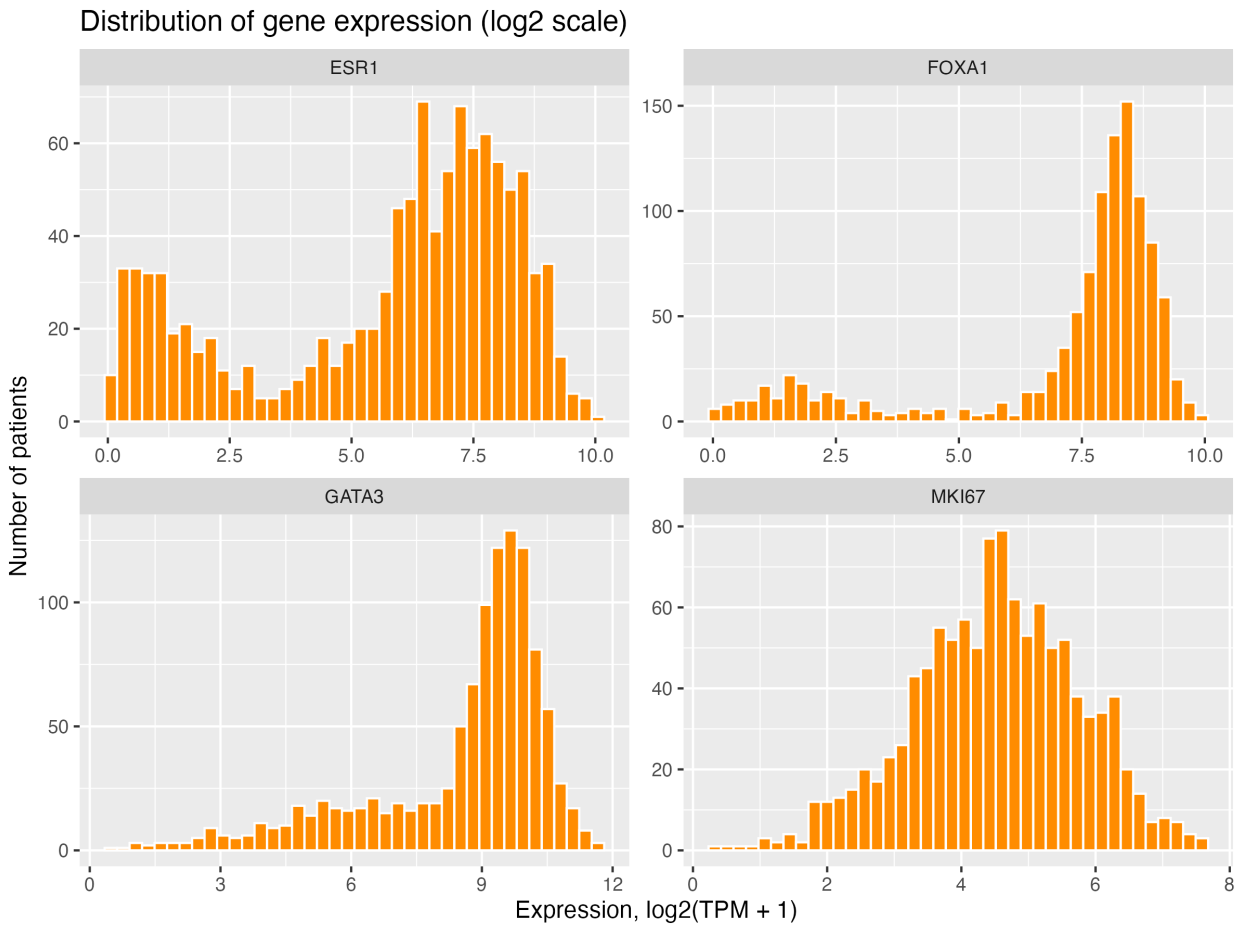
جدول ۹: خلاصه‌ی آماری متغیرهای کمی. بیان ژن در مقیاس لگاریتمی

متغیر	تعداد	گمشده	میانگین	انحراف معیار	میانه	چارک اول	چارک سوم	دامنه‌ی بین‌چارکی
سن، سال	1067	15	59.1	13.2	59.0	49.3	68.0	18.7
گیرنده‌ی استروژن	1082	0	5.71	2.73	6.55	4.06	7.78	3.72
همکار اول	1082	0	8.52	2.10	9.28	7.84	9.87	2.03
همکار دوم	1082	0	7.12	2.46	8.08	7.11	8.56	1.45
نشانگر تکثیر	1082	0	4.51	1.24	4.55	3.69	5.39	1.71

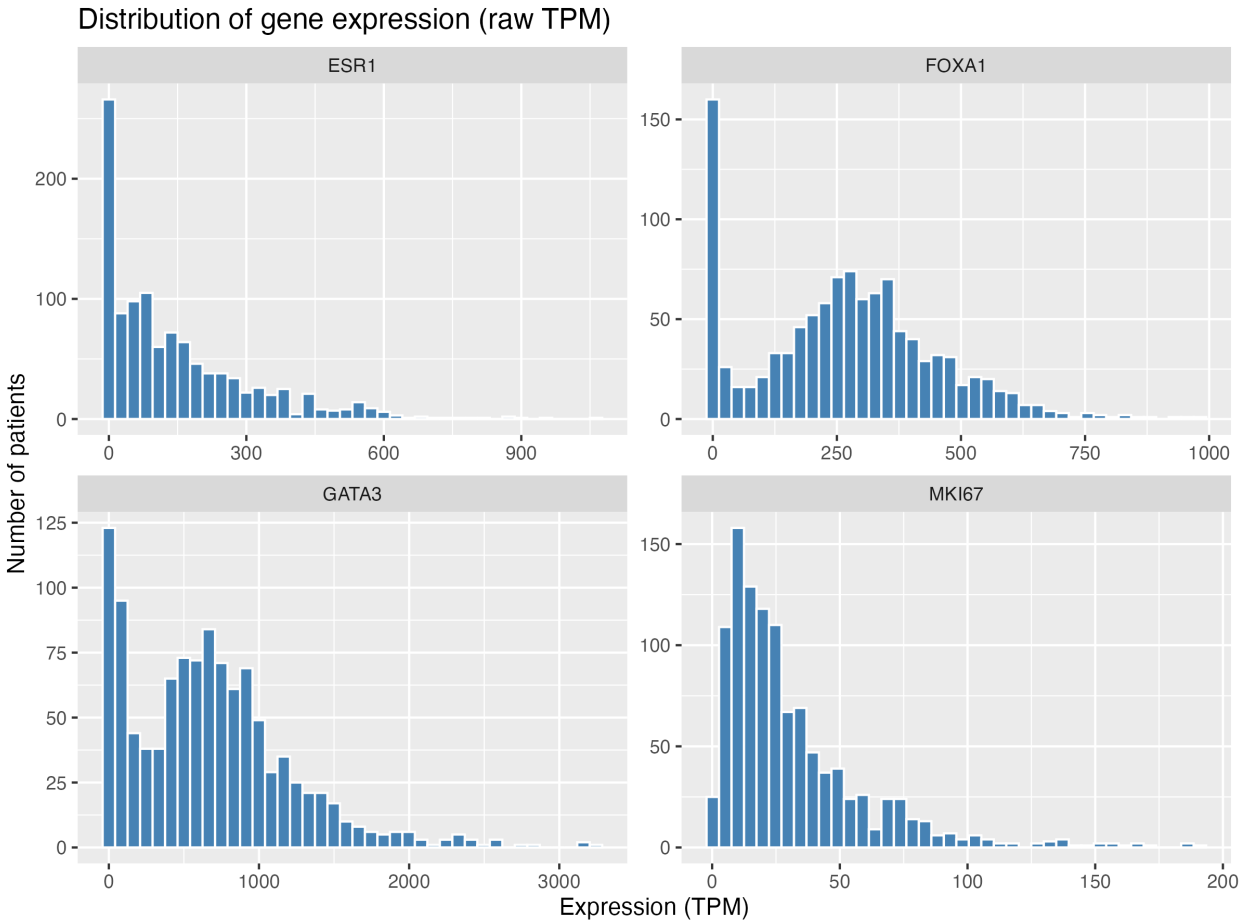
انتخاب معیار مناسب برای مرکز و پراکندگی هر متغیر بر اساس شکل توزیع آن انجام شد. برای این کار دو معیار بررسی شد: نزدیکی میانگین و میانه، و نسبت دامنه‌ی بین‌چارکی به انحراف معیار، که در توزیع نرمال تقریباً ۱٫۳۵ است. سن و بیان نشانگر تکثیر توزیع تقریباً متقارنی دارند: میانگین و میانه‌ی آن‌ها تقریباً برابر است و دامنه‌ی بین‌چارکی آن‌ها نزدیک به مقدار مورد انتظار در توزیع نرمال است؛ بنابراین میانگین و انحراف معیار برای آن‌ها مناسب است. در مقابل، بیان دو ژن همکار گیرنده‌ی استروژن دم چپ دارد: میانگین آن‌ها حدود یک واحد کمتر از میانه است و دامنه‌ی بین‌چارکی، به‌ویژه برای ژن همکار دوم، بسیار کوچک‌تر از مقدار مورد انتظار است. این الگو نشان می‌دهد که بیشتر بیماران در بازه‌ی باریکی قرار دارند، ولی گروه کوچکی با بیان بسیار پایین، میانگین را پایین کشیده و انحراف معیار را افزایش داده است؛ بنابراین میانه و دامنه‌ی بین‌چارکی برای این ژن‌ها مناسب‌تر است. برای ژن همکار دوم، تبدیل لگاریتمی چولگی را افزایش داد و توزیع در مقیاس خام متقارن‌تر بود؛ این یافته نشان می‌دهد تبدیل لگاریتمی برای همه‌ی متغیرها مناسب نیست و در فاز چهارم تنها با دلیل روشن به کار خواهد رفت.

بیان ژن گیرنده‌ی استروژن حالت ویژه‌ای دارد. معیار نسبت دامنه‌ی بین‌چارکی به انحراف معیار برای این ژن مقداری نزدیک به توزیع نرمال نشان می‌دهد، ولی نمودار توزیع آن، شکل ۲، دو قله‌ی مجزا را آشکار می‌کند: یکی نزدیک صفر و دیگری در حدود ۷ تا ۸. در چنین توزیعی، هم میانگین و هم میانه بین دو قله قرار می‌گیرند، یعنی در ناحیه‌ای که بیماران کمی در آن هستند، و هیچ‌کدام به‌تنهایی خلاصه‌ی مناسبی نیستند. بنابراین این متغیر به‌طور جداگانه در هر گروه گیرنده خلاصه شده است، بخش ۱۱. این مورد همچنین نشان می‌دهد که معیارهای عددی به‌تنهایی برای شناخت شکل توزیع کافی نیستند و باید همراه با نمودار بررسی شوند.

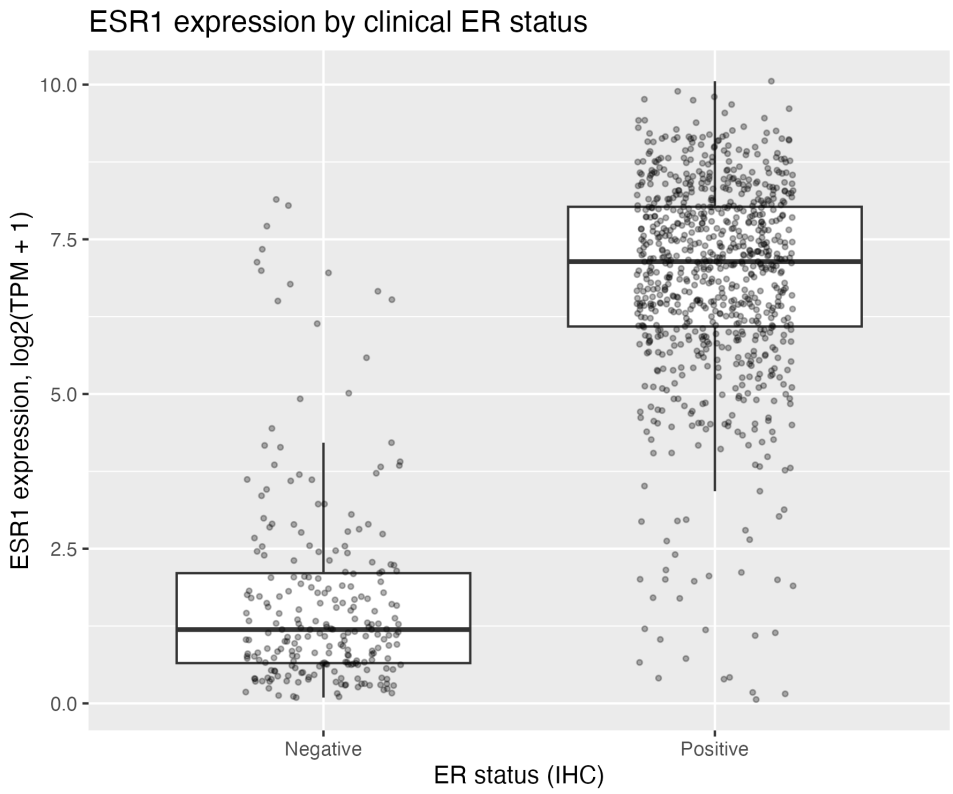
۱۰. نمودارها



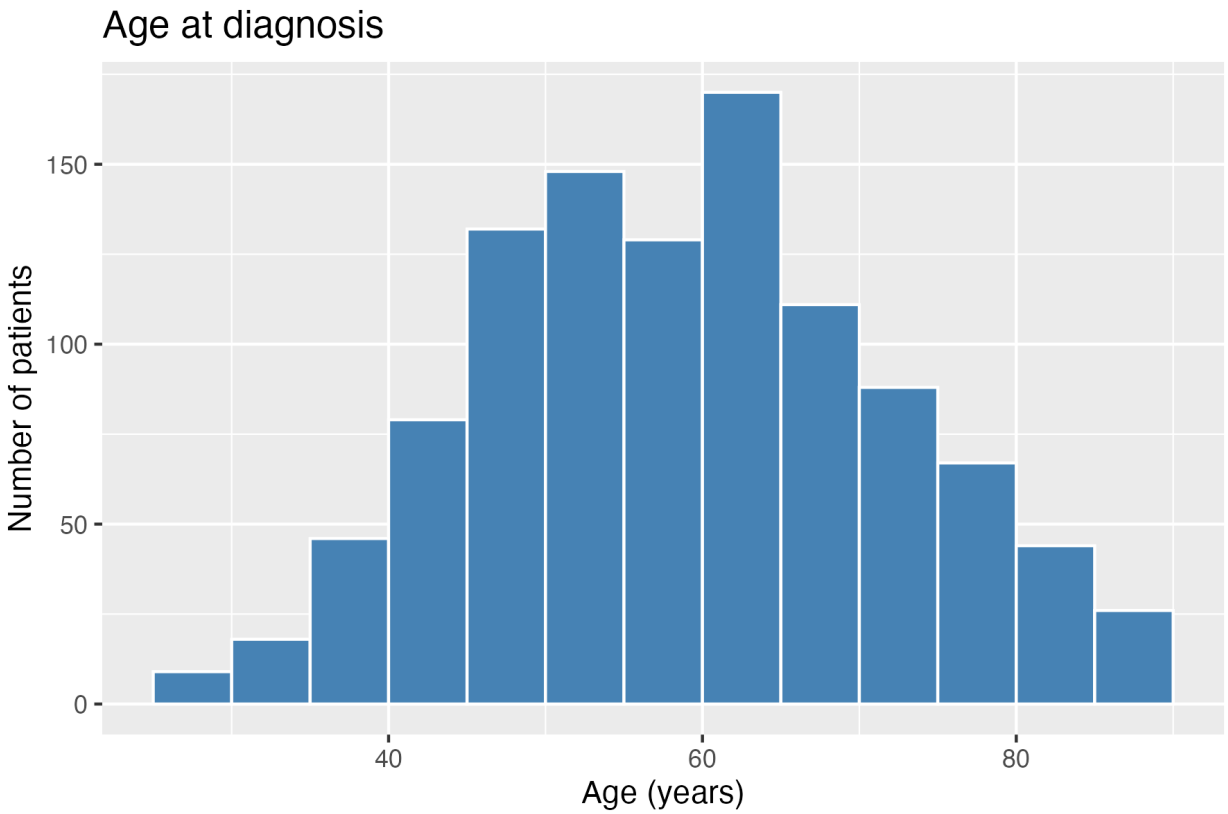
برای نمایش توزیع متغیرهای کمی پیوسته از بافت‌نگار استفاده شد. در مقیاس لگاریتمی، بیان ژن گیرنده‌ی استروژن دو قله‌ی مجزا دارد: یکی نزدیک صفر و دیگری در حدود ۷ تا ۸. بیان دو ژن همکار دم چپ دارد، یعنی گروه کوچکی از بیماران بیان بسیار پایینی دارند، و بیان نشانگر تکثیر تقریباً متقارن است.



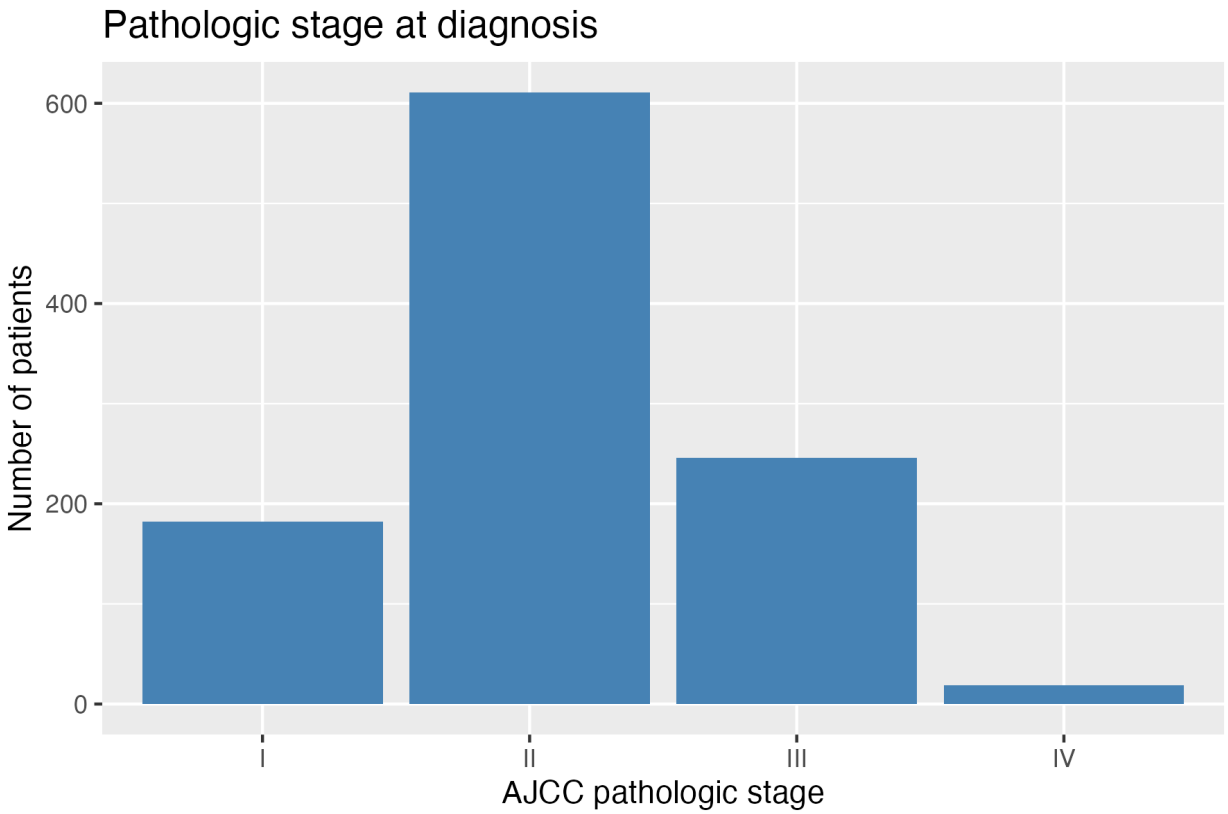
در مقیاس خام، بیان ژن گیرنده‌ی استروژن، ژن همکار اول و نشانگر تکثیر چولگی شدید به راست دارند و چند بیمار مقادیر بسیار بالایی دارند. بیان ژن همکار دوم در این مقیاس نسبتاً متقارن است.
مقایسه‌ی این شکل با شکل ۱ نشان می‌دهد که تبدیل لگاریتمی برای برخی ژن‌ها توزیع را متقارن‌تر می‌کند، ولی برای همه‌ی ژن‌ها مناسب نیست.



برای مقایسه‌ی یک متغیر کمی بین دو گروه، از نمودار جعبه‌ای همراه با نقاط تک‌تک بیماران استفاده شد تا هم خلاصه‌ی توزیع و هم مشاهدات منفرد دیده شوند. بیان ژن گیرنده‌ی استروژن در گروه گیرنده‌مثبت به‌وضوح بالاتر از گروه گیرنده‌منفی است و جعبه‌های دو گروه هم‌پوشانی ندارند. با این حال، تعدادی بیمار ناهمخوان وجود دارد: با آستانه‌های توصیفی دلخواه، ۱۴ بیمار از ۲۳۷ بیمار گیرنده‌منفی، حدود ۶ درصد، بیان بالای ۵ داشتند، و ۳۰ بیمار از ۷۹۵ بیمار گیرنده‌مثبت، حدود ۴ درصد، بیان زیر ۳ داشتند. این ناهمخوانی می‌تواند ناشی از تفاوت بیان ژن و پروتئین، نمونه‌برداری از بخش‌های مختلف تومور، آستانه‌ی پایین مثبت بودن در رنگ‌آمیزی، یا حضور بافت غیرتوموری در نمونه‌ی مولکولی باشد.



سن یک متغیر کمی پیوسته است و با بافت‌نگار با بازه‌های پنج‌ساله نمایش داده شده است. توزیع تک‌قله‌ای و تقریباً متقارن است، با بیشترین تعداد بیماران در حدود ۵۵ تا ۶۰ سالگی، و از حدود ۲۶ تا ۹۰ سال گسترده است. سن ۱۰ بیمار روی سقف ۹۰ سال ثبت شده است.



مرحله‌ی بیماری یک متغیر ترتیبی است، بنابراین از نمودار میله‌ای با ترتیب طبیعی مراحل استفاده شد. نمودار دایره‌ای برای این متغیر مناسب نیست، زیرا ترتیب مراحل را نشان نمی‌دهد. بیشتر بیماران در مرحله‌ی دو قرار دارند و مرحله‌ی چهار تنها ۱۹ بیمار دارد. ۲۴ بیمار با مرحله‌ی نامعلوم در این نمودار نشان داده نشده‌اند.

۱۱. مقایسه‌ی توصیفی دو گروه

جدول ۱۰: بیان ژن گیرنده‌ی استروژن در دو گروه گیرنده، مقیاس لگاریتمی

گروه	تعداد	میانه	چارک اول	چارک سوم	میانگین	انحراف معیار
گیرنده‌منفی	237	1.19	0.65	2.10	1.71	1.63
گیرنده‌مثبت	795	7.14	6.09	8.03	6.88	1.66

جدول ۱۰ بیان ژن گیرنده‌ی استروژن را در دو گروه تعریف‌شده با رنگ‌آمیزی بافت، به‌صورت صرفاً توصیفی مقایسه می‌کند. میانه‌ی بیان در گروه گیرنده‌مثبت ۷٫۱۴ و در گروه گیرنده‌منفی ۱٫۱۹ است. تفاوت حدود ۶ واحد در مقیاس لگاریتم پایه‌ی دو، معادل حدود ۶۰ برابر تفاوت در مقیاس خام است. دامنه‌ی بین‌چارکی دو گروه هم‌پوشانی ندارد، یعنی نیمه‌ی میانی بیماران دو گروه کاملاً از هم جدا هستند. این یافته نشان می‌دهد که دو قله‌ی توزیع بیان این ژن در شکل ۱، عمدتاً با دو گروه بالینی مطابقت دارد و دو روش اندازه‌گیری برای بیشتر بیماران با هم سازگارند. انحراف معیار دو گروه تقریباً برابر است، که برای انتخاب روش مقایسه در فاز سوم اهمیت دارد. در گروه گیرنده‌منفی، میانگین بزرگ‌تر از میانه است، که با وجود تعداد کمی بیمار ناهمخوان با بیان بالا سازگار است، شکل ۳. در این فاز هیچ ادعای استنباطی مطرح نمی‌شود و آزمون رسمی این تفاوت در فاز سوم انجام خواهد شد.

۱۲. سؤال نهایی

با توجه به شناخت حاصل از داده، سؤال اصلی بدون تغییر حفظ شد، زیرا داده‌ی موجود برای پاسخ به آن مناسب است. هر دو وجه مورد نیاز برای تقریباً همه‌ی بیماران در دسترس است، ۹۹۵ بیمار در سه متغیر اصلی داده‌ی کامل دارند، و هر دو گروه گیرنده‌مثبت و گیرنده‌منفی اندازه‌ی کافی برای مقایسه دارند، ۷۹۵ و ۲۳۷ بیمار. تنها محدودسازی انجام‌شده، کنار گذاشتن بیماران مرد است، بنابراین سؤال نهایی به زنان مبتلا محدود می‌شود:

آیا در زنان مبتلا به سرطان مهاجم پستان با نمونه‌ی تومور اولیه، بیان ژن گیرنده‌ی استروژن بین گروه‌های گیرنده‌مثبت و گیرنده‌منفی، بر اساس رنگ‌آمیزی بافت، تفاوت دارد، و آیا این بیان پس از درنظرگرفتن سن و مرحله‌ی بیماری با وضعیت گیرنده و بیان ژن‌های همکار ارتباط دارد؟

بر اساس یافته‌های این فاز، به‌ویژه توزیع دوقله‌ای متغیر پاسخ، در فازهای بعد زیرگروه‌های بسیار کوچک، یعنی مرحله‌ی چهار و حین یائسگی، ممکن است با سطح مجاور ادغام شوند.

۱۳. محدودیت‌ها

نمونه‌گیری غیرتصادفی: بیماران از مراکز همکار و بر اساس دسترسی به بافت مناسب انتخاب شده‌اند، بنابراین نتایج قابل تعمیم به همه‌ی بیماران مبتلا نیست.
مشاهده‌ای بودن مطالعه: هیچ رابطه‌ای در این داده را نمی‌توان به‌صورت علّی تفسیر کرد.
نمونه‌های تکراری: ۱۶ نمونه‌ی اضافه از ۱۱ بیمار با یک قاعده‌ی از پیش تعیین‌شده کنار گذاشته شد. انتخاب قاعده‌ی دیگری، مانند میانگین‌گیری، ممکن است اثر کوچکی بر نتایج داشته باشد.
داده‌ی گمشده: ۸۷ بیمار حداقل یکی از سه متغیر اصلی را ندارند و وضعیت یائسگی برای حدود ۱۰ درصد بیماران نامعلوم است. مقایسه‌ی توصیفی نشانه‌ای از سوگیری نشان نداد، ولی این موضوع قطعی نیست.
زیرگروه‌های کوچک: مرحله‌ی چهار تنها ۱۹ بیمار و حین یائسگی تنها ۳۹ بیمار دارد.
سقف سن: سن ۱۰ بیمار روی ۹۰ سال سقف‌گذاری شده و سن واقعی آن‌ها نامعلوم است.
کنار گذاشتن مردان: نتایج تنها برای زنان معتبر است.
اندازه‌گیری: نمونه‌ی مولکولی ممکن است شامل بافت غیرتوموری باشد، رنگ‌آمیزی و اندازه‌گیری مولکولی ممکن است روی بخش‌های متفاوتی از تومور انجام شده باشند، و بیان ژن لزوماً با مقدار پروتئین برابر نیست. حدود ۴ درصد بیماران بین دو روش اندازه‌گیری ناهمخوانی نشان دادند.

۱۴. منابع

[1] Cancer Genome Atlas Network. Comprehensive molecular portraits of human breast tumours. Nature. 2012;490(7418):61-70. doi:10.1038/nature11412
[2] Hammond MEH, Hayes DF, Dowsett M, et al. American Society of Clinical Oncology/ College of American Pathologists guideline recommendations for immunohistochemical testing of estrogen and progesterone receptors in breast cancer. J Clin Oncol. 2010;28(16):2784-2795.
[3] Kouros-Mehr H, Slorach EM, Sternlicht MD, Werb Z. GATA-3 maintains the differentiation of the luminal cell fate in the mammary gland. Cell. 2006;127(5):1041-1055.
[4] Hurtado A, Holmes KA, Ross-Innes CS, Schmidt D, Carroll JS. FOXA1 is a key determinant of estrogen receptor function and endocrine response. Nat Genet. 2011;43(1):27-33. doi:10.1038/ng.730
[5] Dowsett M, Nielsen TO, A'Hern R, et al. Assessment of Ki67 in breast cancer: recommendations from the International Ki67 in Breast Cancer Working Group. J Natl Cancer Inst. 2011;103(22):1656-1664.